

KREDİ KARTI MÜŞTERİ CHURN ANALİZİ

Maliyet Odaklı Tahminleme ve Finansal Simülasyon

Metin Mutlu — 132230127

10.127

Müşteri

2 Kaynak

Data Fusion

AUC 0.9856

Model Başarısı

+92.150 TL

Optimizasyon

GitHub: <https://github.com/mtnmtlu/kredi-karti-musteri-churn-analizi>Veri Seti Drive: <https://drive.google.com/drive/folders/1urzrx-bEbJb-aHDbIK91vUf4Y8VdDKOd>

1. Giriş ve Problem Tanımı

Bankacılık sektöründe müşteri sadakati, kurumun uzun vadeli finansal sürdürülebilirliğinin temel belirleyicilerinden biri olarak kabul edilmektedir. Literatürdeki pek çok çalışma, mevcut bir müşteriyi elde tutmanın yeni bir müşteri kazanımına kıyasla beş ila yüz kat daha düşük maliyetli olduğunu ortaya koymaktadır. Bu gerçeklik, müşteri kaybı (churn) tahmininin bankacılık analitiği alanındaki en kritik problemlerden biri haline gelmesine zemin hazırlamıştır.

Bu çalışmada, bir bankanın kredi kartı portföyünden derlenen 10.127 müşteriye ait demografik ve finansal veriler kullanılarak hangi müşterilerin kartı bırakmaya (churn) meyilli olduğu önceden tahmin edilmeye çalışılmıştır. Çalışmanın standart churn tahmin yaklaşımlarından ayrıştığı iki temel nokta bulunmaktadır: Birincisi, tek bir veri kaynağı kullanmak yerine iki farklı kaynak anlamlı biçimde birleştirilmiş; bu harmanlama saf bir iş mantığıyla yeni değişkenler türetmek için kullanılmıştır. İkincisi, modelin başarısı yalnızca teknik doğruluk metrikleriyle değil, doğrudan finansal bir ROI senaryosuyla kanıtlanmıştır.

Çalışmada ayrıca standart çözüm yaklaşımında yaygın olarak kullanılan tahmin eşiği değeri olan 0.50'nin, asimetrik maliyet yapısına sahip churn problemleri için finansal olarak neden yetersiz olduğu matematiksel olarak gösterilmiş ve optimal eşik değeri deneysel olarak belirlenmiştir.

Araştırma Soruları

- Hangi müşteri segmenti en yüksek churn riskine sahiptir ve belirleyici özellikler nelerdir?
- SHAP analizi hangi değişkenleri belirleyici bulmakta; bulgular iş kararı perspektifinden nasıl yorumlanmalıdır?
- Hangi tahmin eşiğinde elde tutma kampanyasının net karı maksimum olur? Standart 0.50 eşiği finansal olarak neden yetersizdir?

2. Veri Kaynakları ve Harmanlama (Data Fusion)

Kaynak	İçerik	Kullanım Amacı
BankChurners.csv (Kaggle)	10.127 müşteri, 23 değişken: demografik + hesap + davranışsal metrikler. Hedef: Attrition_Flag (%16.1 churn)	Ana tahmin değişkenleri. Sınıf dengesizliği nedeniyle accuracy yerine AUC-ROC kullanıldı.
enflasyon.csv (TCMB)	2016–2021 yıllık TÜFE enflasyon oranı ve politika faizi. 6 satır, 3 sütun.	Müşterinin bankaya katılım dönemindeki makroekonomik bağlamı modele kazandırmak.

Harmanlama mekanizması: $katilim_yılı = 2021 - \text{yuvarlama}(\text{Months_on_book} / 12)$ formülüyle türetilmiş, TCMB tablosuyla LEFT JOIN uygulanmıştır.

2018 yılında %20 enflasyon yaşanırken nominal harcama artışı gerçek satın alma gününü yansıtmamaktadır. Enflasyona göre düzeltilmiş harcama değişkeni (reel_harcama_değişimi) bu harmanlamanın doğrudan çıktısıdır.

3. İş Mantığına Dayalı Özellik Mühendisliği

Bu çalışmada her biri bağımsız bir iş hipotezine dayanan üç yeni değişken türetilmiştir.

3.1. müşteri_yaşam_değeri (Müşteri Yaşam Değeri Proxy'si)

Formül: $müşteri_yaşam_değeri = Total_Trans_Amt \times (Months_on_book / 12)$

Bu değişken, müşterinin bankada kaldığı süre boyunca oluşturduğu tahmini kümülatif işlem hacmini temsil etmektedir. Müşteri yaşam değeri (Customer Lifetime Value — CLV) hesaplamasının basitleştirilmiş bir yansıması olan bu metrik, hem işlem tutarını hem de müşteri süresini tek bir skaler değerde birleştirmektedir. Düşük bir yaşam değeri, müşterinin ya çok kısa süre bulunduğunu ya da bulunduğu süre boyunca kartını aktif kullanmadığını göstermekte; her iki durum da churn riskinin artmış olduğuna işaret etmektedir.

3.2. reel_harcama_değişimi (Data Fusion'ın Kilit Özelliği)

Formül: $reel_harcama_değişimi = Total_Amt_Chng_Q4_Q1 / (1 + enflasyon\ oranı / 100)$

Bu değişken, çalışmanın Data Fusion gereksinimini doğrudan karşılayan kilit özelliktir. BankChurners verisinde hali hazırda bulunan Total_Amt_Chng_Q4_Q1 sütunu, müşterinin son çeyrekteki (Q4) harcama değişimini ilk çeyrektekiyle (Q1) karşılaştıran nominal bir oran sunmaktadır. Ancak bu oran enflasyona göre düzeltilmeden incelendiğinde, yüksek enflasyon dönemlerinde satın alma gününü yanlış değerlendirme riski taşımaktadır. TCMB enflasyon verisiyle harmanlama sayesinde bu nominal değişim reel değere dönüştürülmüş; 2018 gibi yüksek enflasyon yaşanan yıllarda bankaya katılan müşterilerin nominal harcama artışı, genel fiyat artışından arındırılmıştır.

3.3. aktiflik skoru (RFM Benzeri Bağlılık Endeksi)

Formül: $aktiflik\ skoru = Total_Trans_Ct \times (1 - Months_Inactive_12_mon / 12) / (Contacts_Count_12_mon + 1)$

Bu değişken, pazarlama literatüründeki RFM (Recency, Frequency, Monetary) modelinden esinlenerek tasarlanmıştır. Payındaki çarpım işlemi, yüksek işlem sayısını düşük inaktiflik oranıyla birleştirerek "aktif ve üretken" müşteriye tanımlamaktadır. Payda ise müşterinin bankayı kaç kez aradığını (şikâyet yükü) temsil etmekte; yüksek irtibat sayısı genellikle müşteri memnuniyetsizliğinin işareti olduğundan skoru aşağı çekmektedir. Skoru yüksek müşteri "çok işlem yapan, az şikâyet eden ve az inaktif kalan" profilini yansıtırken; düşük skor kritik churn sinyali olarak işlev görmektedir.

Değişken	Formül	Gerekçe ve SHAP Kanıtı
müşteri_yaşam_değeri	$Total_Trans_Amt \times (Months / 12)$	Kümülatif müşteri değeri (CLV Proxy). Düşük CLV = kısa süre veya az işlem = yüksek churn riski.
reel_harcama_değişimi	$Amt_Chng_Q4_Q1 / (1 + enfl/100)$	Data Fusion çıktısı: nominal harcama değişimi enflasyona göre düzeltilir. Gerçek satın alma gününü yansıtır.
aktiflik_skoru	$Trans_Ct \times (1 - inaktif) / (şikayet+1)$	RFM benzeri bağlılık endeksi. Üç değişken de SHAP'ta ilk 5 arasına girmiş, özellik mühendisliğinin modele katma değer sağladığı kanıtlanmıştır.

4. Keşifçi Veri Analizi (EDA)

Modelleme öncesinde, veri setinin yapısını, değişkenler arasındaki ilişkileri ve hedef değişken üzerindeki etkili faktörleri anlayabilmek amacıyla kapsamlı bir keşifçi veri analizi gerçekleştirilmiştir. Bu aşamada çeşitli görselleştirmeler oluşturulmuş; dağılım grafikleri, kutu-çizimi (boxplot) karşılaştırmaları ve korelasyon matrisi incelenmiştir.

4.1. Sınıf Dengesizliği ve Metodolojik Etkisi

Veri setinde 8.500 kalan (%83.9) ve 1.627 churn eden (%16.1) müşteri bulunmaktadır. Bu dengesiz dağılım, doğruluk (accuracy) metriğini temel değerlendirme kriteri olarak kullanmayı anlamsız kılmaktadır. Model hiç eğitilmeden tüm müşteriler için "kalan" tahmin eden bir yaklaşım dahi %84 doğruluk elde edebilmektedir. Bu nedenle değerlendirme metrikleri olarak AUC-ROC, precision, recall ve F1-score tercih edilmiş; model eğitiminde class_weight="balanced" parametresi kullanılmıştır.

4.2. Temel İstatistiksel Bulgular

Churn değişkeniyle en güçlü negatif korelasyona sahip değişkenler sırasıyla Total_Trans_Ct (-0.37), Total_Trans_Amt (-0.26) ve Avg_Utilization_Ratio (-0.18) olarak belirlenmiştir. Pozitif yöndeki en güçlü korelasyon ise Months_Inactive_12_mon (+0.20) ile gözlenmektedir. Bu bulgular, müşterinin kartı aktif kullanımının churn karşısında en güçlü koruyucu faktör olduğuna işaret etmekte; inaktif geçirilen ay sayısının artışı ise churn olasılığını belirgin biçimde yükseltmektedir.

Metrik	Kalan	Ayrılan
Ortalama işlem tutarı (12 ay)	4.653 TL	3.095 TL
Ortalama işlem sayısı (12 ay)	68	45
Ortalama inaktif ay	2.3 ay	3.4 ay
Ortalama aktiflik_skoru (yeni)	26.8	12.1

i Churn eden müşteri ayrılmadan 2–3 ay önce "sessizleşmektedir": işlem sayısı %34 azalıyor, aktiflik skoru yarıya düşüyor. Bu pencere erken uyarı sisteminin operasyonel tasarımı için kritik fırsat sunmaktadır.

5. Model Seçimi ve Performans Değerlendirmesi

class_weight="balanced" parametresiyle Random Forest Classifier seçilmiştir. Üç gerekçe: (1) sınıf dengesizliğini yapay veri üretmeden ağırlandırması, (2) SHAP TreeExplainer uyumluluğu, (3) 200 ağaçlı yapının overfitting riskini azaltması.

Metrik	Değer	İş Yorumu
AUC-ROC (Test Seti)	0.9856	Rastgele modele kıyasla son derece güçlü ayırt edicilik. Churn eden ile kalanlar neredeyse hiç karıştırılmıyor.
5-Fold CV AUC	0.9272±0.001	Düşük standart sapma overfitting olmadığını kanıtıyor; model yeni verilere genellenebilir.
Precision/Recall/F1 (Churn)	0.85 / 0.85 / 0.85	Dengeli metrikler modelin ne fazla yanlış alarm ne de fazla kaçırma yaptığını gösteriyor.

i Yüksek AUC modelin "iyi" olduğunu gösterir; fakat "ne kadar finansal değer üreteceği" sorusu teknik metriklerle yanıtlanamaz. Aynı model farklı eşiklerle çok farklı finansal sonuçlar doğurur — bu 7. bölümde kanıtlanmaktadır.

6. Açıklanabilir Yapay Zeka (XAI) — SHAP Analizi

Makine öğrenmesi modellerinin kurumsal ortamlarda benimsenmesinin önündeki en büyük engellerden biri, kararlarının açıklanamamasıdır. Bir kredi kartı müşterisi için neden kampanya gönderildiğini banka yönetimine ifade edebilmek, yasal uyum ve iş güveni açısından kritiktir. Bu çalışmada modelin "kara kutu" olmaktan çıkarılması için SHAP (SHapley Additive exPlanations) kullanılmıştır.

SHAP, oyun teorisinden türetilen Shapley değerlerini temel almakta ve her değişkenin modelin nihai tahmininden aldığı payı hesaplamaktadır. Pozitif bir SHAP değeri o değişkenin churn olasılığını artırdığını, negatif bir değer ise azalttığını göstermektedir.

6.1. En Etkili 5 Değişken ve Ayrıntılı İş Yorumu

Değişken	Ayrıntılı İş Yorumu
1. Total_Trans_Ct	Son 12 aydaki işlem sayısı tek başına en güçlü churn öncüsüdür. 45 işlemin altına düşen müşteriler kritik risk grubunu oluşturmaktadır. Bu eşğin altındaki her ekstra işlem eksikliği churn olasılığını dikkate değer biçimde artırmaktadır. Kartını bırakacak müşteri, bunu yapmadan 2-3 ay önce işlem sıklığını düşürmeye başlamaktadır.
2. Total_Trans_Amt	Toplam işlem tutarının düşmesi, işlem sayısından bağımsız bir churn sinyali sunmaktadır. Düşük tutarlı işlem yapan müşteriler kartı günlük hayatta merkezi bir ödeme aracı olarak benimsememiştir. Bu durum bağlılığı azaltmakta ve churn riskini artırmaktadır.
3. aktiflik_skoru *	Bu çalışmada türetilen yeni değişken üçüncü sıraya ulaşmıştır. Bu, özellik mühendisliğinin modele gerçek katma değer sağladığının nesnel kanıtıdır. İşlem sıklığı, inaktiflik oranı ve şikâyet yükünü tek bir skallerde birleştiren bu değişken, bireysel ham değişkenlerden daha zengin bir bilgi temsili sunmaktadır.
4. Total_Revolving_Bal	Dönen bakiyesi düşük müşteri, krediyi aktif olarak kullanmıyor demektir. Bu durum müşterinin bankayla olan finansal bağının zayıfladığına işaret etmektedir. Dönen bakiye arttıkça müşteri ürünü daha etkin kullanmakta ve churn riski azalmaktadır.
5. Avg_Utilization_Ratio	Kredi limitini az kullanan müşteri kartını günlük yaşamına entegre etmemiştir. Kullanım oranı sıfıra yakın olan müşteriler işlevsel olarak karttan bağımsız yaşayan profili yansıtmakta ve churn olasılığı belirgin biçimde yükselmektedir.

* Yıldız işaretli değişken bu çalışmada türetilmiştir; ham veride mevcut değildir.

7. Finansal Simülasyon ve Optimal Eşik Belirleme

Bu bölüm, çalışmanın makine öğrenmesi çıktısının doğrudan finansal bir ROI hesabına dönüştürülmesini kapsamaktadır. Standart yaklaşımın finansal olarak neden yetersiz olduğu matematiksel hesaplama üzerinden gösterilmektedir.

7.1. Asimetrik Maliyet Matrisi

Churn problemlerinin standart ikili sınıflandırma problemlerinden ayrılan temel özelliği, yanlış negatif (FN) ve yanlış pozitif (FP) hatalarının çok farklı finansal bedeller taşımasıdır. Bu çalışmada aşağıdaki maliyet parametreleri tanımlanmıştır: Bir müşterinin bankaya yıllık net değeri (LTV) 1.500 TL, elde tutma promosyon maliyeti 100 TL ve kampanyanın churn önleme başarı oranı %70 olarak alınmıştır.

Tahmin	Gerçek	Durum	Net Finansal Etki ve Hesaplama Mantığı
Churn	Churn	TP	+950 TL: Kampanya gönderildi. %70 olasılıkla müşteri kalıyor. Beklenen değer: $0,70 \times (1.500 \text{ TL} - 100 \text{ TL}) + 0,30 \times (-100 \text{ TL}) = +950 \text{ TL}$
Churn	Kalan	FP	-100 TL: Gitmeyen bir müşteriye boşa promosyon gönderildi. Yalnızca kampanya maliyeti kayıp.
Kalan	Churn	FN	-1.500 TL: Churn eden müşteriye hiçbir müdahale yapılmadı. Yıllık LTV tamamen kayboldu. Bu maliyet FP maliyetinin 15 katıdır!
Kalan	Kalan	TN	0 TL: Doğru karar; hareketsiz kalındı, herhangi bir maliyet ya da kazanç yok.

FP maliyeti (100 TL) ile FN maliyeti (1.500 TL) arasındaki 15:1 oranı bu problemin asimetrik yapısını özetlemektedir. Bir churner'ı kaçırmak, 15 kişiye yanlış alarm vermekten daha pahalıdır. Bu durum, modelin "daha hassas" (recall odaklı) çalıştırılmasını — yani eşğin düşürülmesini — bu asimetrik yapıda finansal olarak optimal kılmaktadır.

7.2. Eşik Optimizasyonu ve Sonuçları

Test veri seti üzerinde tahmin eşiği 0.05 ile 0.90 arasında 0.01 artımlarla taranmış; her değer için TP, FP, FN ve TN sayıları hesaplanmış ve maliyet matrisi uygulanmıştır.

Senaryo	Eşik	TP	FP	FN	Net Kar
Standart uygulama	0.50	278	47	47	184.000 TL
OPTIMAL (bu çalışmada)	0.20	321	208	4	276.150 TL
Ek katkı	—	+43	+161	-43	+92.150 TL

Optimal eşiğe geçildiğinde FP sayısı 47'den 208'e yükselmektedir. Bu ilk bakışta olumsuz görünebilir; ancak maliyet analizi yapıldığında tablo değişir. Ek 161 FP, $161 \times 100 \text{ TL} = 16.100 \text{ TL}$ ek maliyet getirirken; kurtarılan 43 TP, $43 \times 950 \text{ TL} = 40.850 \text{ TL}$ değer üretmekte; azaltılan 43 FN ise $43 \times 1.500 \text{ TL} = 64.500 \text{ TL}$ kayıptan kurtulmaktadır. Net fark: $40.850 + 64.500 - 16.100 = +89.250 \text{ TL}$ (yuvarlama farkıyla toplam katkı +92.150 TL olarak hesaplanmıştır). Bu hesaplama, asimetrik maliyet yapısının eşik optimizasyonunu finansal olarak zorunlu kıldığını açıkça ortaya koymaktadır.

TEMEL SONUÇ: 0.20 eşiği ile 325 gerçek churner'dan 321'i (%98.8) tespit edilmiştir. Standart uygulamaya kıyasla test setinde +92.150 TL ek finansal değer üretilmektedir.

8. Sonuç ve İş Önerileri

Bu çalışma, AUC 0.9856 gibi yüksek teknik başarıya rağmen standart 0.50 eşiğinin 92.150 TL finansal değeri masada bıraktığını kanıtlamaktadır. Data Fusion ile türetilen reel_harcama_değişimi ve aktiflik_skoru, SHAP tarafından istatistiksel olarak doğrulanmış; özellik mühendisliğinin modele gerçek katma değer sağladığı nesnel biçimde gösterilmiştir.

Öneri	Eylem	Beklenen Etki
Eşik güncelleme	Chum modeli eşiğini 0.50'den 0.20'ye indirin.	+92.150 TL/dönem
Erken müdahale	aktiflik_skoru < 10 olanlara 30. günde kampanya tetikleyin.	İnaktiflik kriz olmadan önleme
Segmentçe kampanya	CLV proxy < 6.000 TL olan müşterilere öncelik verin.	ROI maksimizasyonu
Aylık izleme	Total_Trans_Ct aniden düşenlere otomatik alarm kurun.	Erken uyarı mekanizması